Lab2 test report

Team：一朵鲜花三根草

1. 实验概要

使用网络编程知识，从零开始实现一个基于 HTTP/1.1 的 HTTP 服务器，并尝试使用从课堂上中学习的高并发编程技能来保证 web 服务器的性能。最后对服务器进行并发测试，比较不同环境下服务器的性能。

1.1 程序输入

无。

1.2 程序输出

服务器端：输出建立连接和请求类型的信息

客户端：显示 HTTP 响应报文

1.3 性能指标

服务器单位时间内可以处理多少 HTTP 请求，或处理一个 HTTP 请求所用的时间。

1.4 实验环境

使用实验中共有 2 个不同的实验环境：ENV1 和 ENV2。

ENV1：linux 内核版本为 Linux ubuntu 4.4.0-148-generic #174~14.04.1-Ubuntu SMP；2GB 内存；CPU 型号为 Intel(R) Core(TM) i5-6300HQ CPU @ 2.30GHz，共有 1 个物理 CPU；每个物理 CPU 有 4 个物理核心，共有 4 个物理核心；不使用超线程技术。

ENV2-1：linux 内核版本为 Linux ubuntu 4.15.0-96-generic #97~16.04.1-Ubuntu SMP；2GB 内存；CPU 型号为 Intel(R) Core(TM) i7-7500U CPU @ 2.70GHz，共 2 个物理 CPU；每个物理 CPU 有 1 个物理核心，共有 2 个物理核心；不使用超线程技术。

ENV2-2：linux 内核版本为 Linux ubuntu 4.15.0-96-generic #97~16.04.1-Ubuntu SMP；2GB 内存；CPU 型号为 Intel(R) Core(TM) i7-7500U CPU @ 2.70GHz，共 2 个物理 CPU；每个物理 CPU 有 2 个物理核心，共有 4 个物理核心；不使用超线程技术。

1.5 代码实现版本

本次实验中实现的是基础版本，可以处理客户端的 GET、POST 请求，对其他请求返回

501 未实现错误，每个 TCP 连接在同一时间只有一个请求。使用了线程池来增加并发性，线程池中线程的数目在启动服务器时由--number-thread 参数确定。

2. 性能测试

使用 apache 完成性能测试。

2.1 改变服务器及其环境，测试每秒可以处理多少 HTTP 请求

2.1.1 改变线程池中的线程数(ENV1)

-n 5000 (Number of requests to perform for the benchmarking session.)

-c 200 (Number of multiple requests to perform at a time.)

对 index.html 进行请求，记录大小为 1652 字节。

先提前解释一下以下 apache 测试结果中的内容：

erver Software: //被测试的服务器所用的软件信息

Server Hostname: //被测主机名

Server Port://被测主机的服务端口号

Document Path: //请求的具体文件

Document Length://请求的文件的大小

Concurrency Level: //并发级别，也就是并发数，请求中一c 参数指定的数量

Time taken for tests: //本次测试总共花费的时间

Complete requests: //本次测试总共发起的请求数量

Failed requests://失败的请求数量。因网络原因或服务器性能原因，发起的请求并不一定全部成功，通过该数值和 Complete requests 相除可以计算请求的失败率，作为测试结果的重要参考。

Total transferred: //总共传输的数据量，指的是 ab 从被测服务器接收到的总数据量，包括 index.html 的文本内容和请求头信息。

HTML transferred://从服务器接收到的 index.html 文件的总大小，等于 Document Length＊Complete requests

Requests per second://平均(mean)每秒完成的请求数：QPS，这是一个平均值

Time per request: (mean) //从用户角度看，完成一个请求所需要的时间

Time per request: (mean, across all concurrent requests)// 服务器完成一个请求的时间。

Transfer rate: [Kbytes/sec] received //网络传输速度。对于大文件的请求测试，这个值很容易成为系统瓶颈所在。要确定该值是不是瓶颈，需要了解客户端和被测服务器之间的网络情况，包括网络带宽和网卡速度等信息。

```
Connection Times (ms)
              min  mean[+/-sd] median   max
Connect:        0   14 116.9      0    1032
Processing:     1   41  17.2     41      95
Waiting:        1   40  17.1     41      94
Total:          9   55 118.7     42    1096
```

这几行组成的表格主要是针对响应时间也就是第一个 Time per request 进行细分和统计。一个请求的响应时间可以分成网络链接（Connect），系统处理（Processing）和等待（Waiting）三个部分。表中 min 表示最小值；mean 表示平均值；[+/-sd]表示标准差（Standard Deviation），也称均方差（mean square error）；median 表示中位数；max 当然就是表示最大值了。

需要注意的是表中的 Total 并不等于前三行数据相加，因为前三行的数据并不是在同一个请求中采集到的，可能某个请求的网络延迟最短，但是系统处理时间又是最长的。所以 Total 是从整个请求所需要的时间的角度来统计的。这里可以看到最慢的一个请求花费了 27.773s，这个数据可以在下面的表中得到验证。

```
Percentage of the requests served within a certain time (ms)
  50%     42
  66%     49
  75%     54
  80%     57
  90%     64
  95%     70
  98%     79
  99%   1050
 100%   1096 (longest request)
```

表二：这个表第一行表示有 50%的请求都是在 121ms 内完成的。以此类推，90%的请求是小于等于 1207ms 的。刚才我们看到响应时间最长的那个请求是 27773ms，那么显然所有请求（100%）的时间都是小于等于 27773 毫秒的，也就是表中最后一行的数据肯定是时间最长的那个请求（longest request）。

ENV1 下改变线程数目处理每个请求所需时间的变化：

ThreadNum	时间/ms							
	1	2	3	4	5	前三平均	中三平均	后三平均
1	0.821	0.504	0.540	0.423	0.442	0.622	0.489	0.468
2	0.737	0.710	0.668	0.458	0.452	0.705	0.612	0.526
4	0.772	0.758	0.510	0.422	0.396	0.680	0.563	0.443
6	0.756	0.542	0.531	0.441	0.489	0.610	0.505	0.487
8	0.800	0.538	0.493	0.488	0.503	0.610	0.506	0.495

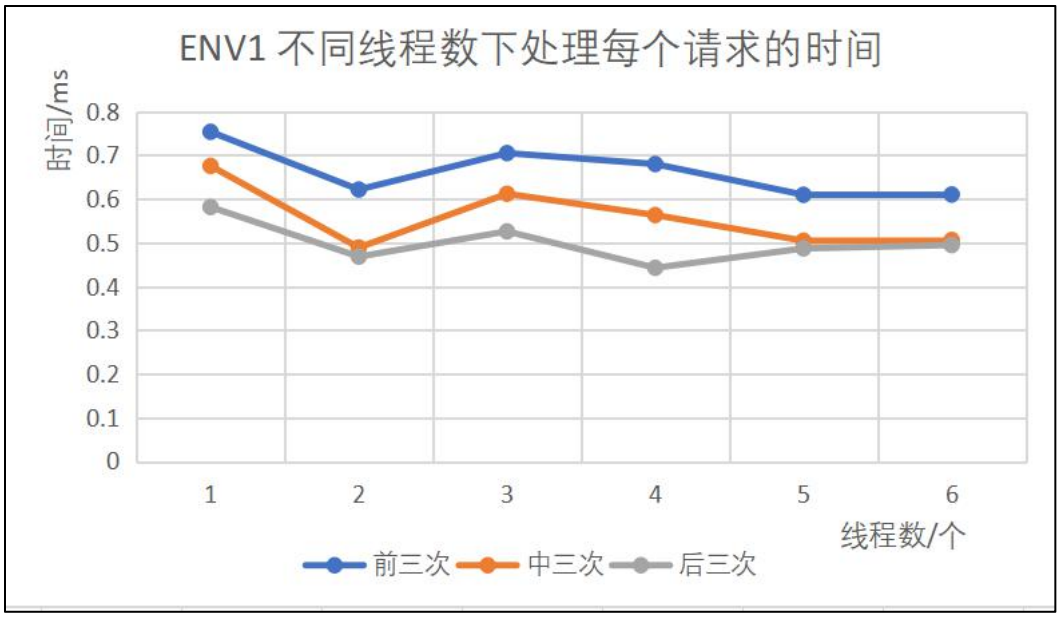

2.1.2 改变线程池中的线程数和 CPU 核数(ENV2)

ENV2-1 下改变线程数目处理每个请求所需时间的变化：

ThreadNum	时间/ms							
	1	2	3	4	5	前三平均	中三平均	后三平均
0	1.544	0.871	0.875	0.873	0.865	1.097	0.873	0.871
1	1.254	0.735	0.611	0.781	0.663	0.867	0.709	0.685
2	1.054	0.661	0.619	0.608	0.538	0.778	0.629	0.588
3	1.029	0.783	0.681	0.552	0.607	0.831	0.672	0.613
4	1.087	0.706	0.659	0.540	0.591	0.817	0.635	0.597
6	1.172	0.705	0.631	0.565	0.554	0.836	0.634	0.583
8	1.192	0.693	0.700	0.550	0.503	0.862	0.648	0.584

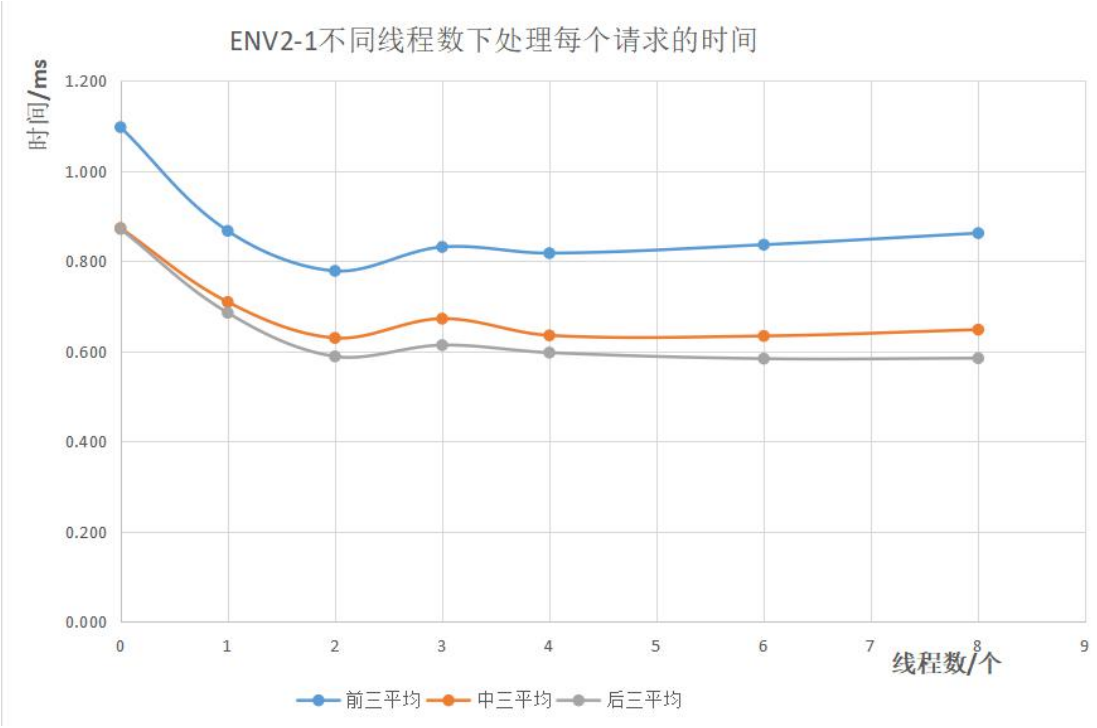

ENV2-2 下改变线程数目处理每个请求所需时间的变化：

ThreadNum	时间/ms							
	1	2	3	4	5	前三平均	中三平均	后三平均
0	0.872	0.693	0.545	0.544	0.537	0.703	0.594	0.542
1	0.771	0.551	0.470	0.481	0.400	0.597	0.501	0.450
2	0.725	0.599	0.411	0.392	0.367	0.578	0.467	0.390
3	0.708	0.718	0.427	0.349	0.421	0.618	0.498	0.399
4	0.673	0.552	0.394	0.376	0.399	0.540	0.441	0.390
6	0.936	0.521	0.410	0.504	0.362	0.622	0.478	0.425
8	0.860	0.583	0.422	0.424	0.379	0.622	0.476	0.408

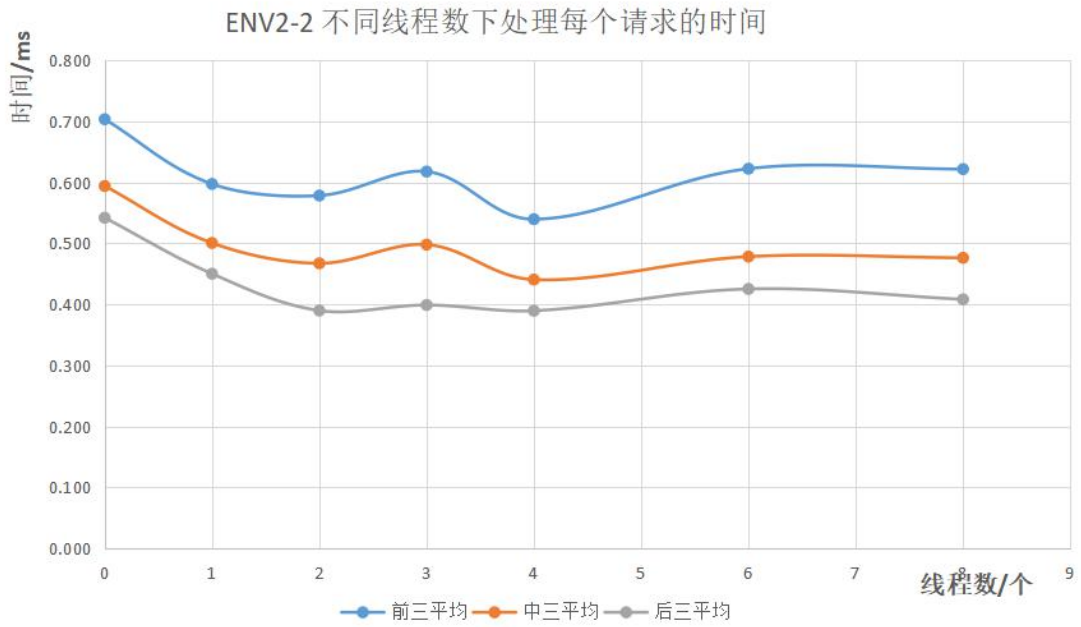

number-thread 为 0 时，是一个动态上线的线程池。

同是 4 核下，ENV2-2 下比 ENV1 下性能更好一些。另外从图表中看出：

1. 启动服务器后进行多次测试，请求响应时间呈下降趋势（因为第一次测试时有创建连接的开销）。

2. --number-thread 为 2 时基本已经达到瓶颈，后续再增加线程数量，对请求的响应时间没有什么减少，甚至还会小幅度上升。

2.2 总结

关于两线程达到性能瓶颈问题，我们可以具体参考 2 号环境下的测试结果，2 核和四核间似乎并没有两倍的性能差距要么是双核快了，要么是四核慢了。这可能和进程调度的算法有关，线程数开多了以后，调度算法吃资源效率没有利用好，那么也就是没有利用完全资源；或者另一种考虑即双核快了，由于虚拟机默认双线程，也许有一些内部快速通道所导致。

关于优化问题，线程的具体工作为：获取 socket 的 I/O 流对象，通过输入流构造 Http 请求我们将其简称为 worker 线程。考虑后续优化问题，优化读写能力是一个方面，进一步可以考虑对 worker 进行细致拆分，每个线程即负责 IO 读取，也负责工作处理，这样性能应该会有进一步的提升。